# Рубежный контроль №2

### Прошкин Георгий, ИУ5-61Б

### Вариант 13

Задание. Для заданного набора данных построить модели логистической регрессии и случайного леса. Оценить качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

Метод №1: Линейная/логистическая регрессия

Метод №2: Случайный лес

```
import numpy as np
import pandas as pd
from sklearn.preprocessing import LabelEncoder, MinMaxScaler
from sklearn.model selection import train test split
from sklearn.linear model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy score, precision score,
recall score
df = pd.read csv('marvel-wikia-data.csv')
df.head()
   page id
                                            name
0
      1678
                       Spider-Man (Peter Parker)
      7139
                Captain America (Steven Rogers)
1
            Wolverine (James \"Logan\" Howlett)
2
     64786
3
              Iron Man (Anthony \"Tony\" Stark)
      1868
4
                             Thor (Thor Odinson)
      2460
                                    urlslua
                                                            ID
0
               \/Spider-Man (Peter Parker)
                                              Secret Identity
         \/Captain America (Steven Rogers)
1
                                              Public Identity
2
   \/Wolverine_(James_%22Logan%22_Howlett)
                                              Public Identity
     \/Iron_Man_(Anthony_%22Tony%\overline{2}2 Stark)
3
                                              Public Identity
                      \/Thor (Thor Odinson)
                                             No Dual Identity
                ALIGN
                                                                  GSM
                               EYE
                                          HAIR
                                                             SEX
                                                                      \
      Good Characters Hazel Eyes
0
                                    Brown Hair
                                                Male Characters
                                                                  NaN
1
      Good Characters
                         Blue Eves
                                    White Hair
                                                Male Characters
                                                                  NaN
```

```
Neutral Characters
                        Blue Eves
                                    Black Hair
                                                Male Characters
2
                                                                  NaN
3
      Good Characters
                        Blue Eves
                                    Black Hair
                                                Male Characters
                                                                  NaN
      Good Characters
                        Blue Eyes Blond Hair Male Characters
4
                                                                  NaN
               ALIVE APPEARANCES FIRST APPEARANCE
                                                       Year
                                                     1962.0
   Living Characters
                            4043.0
                                             Aug - 62
  Living Characters
                            3360.0
                                             Mar-41
                                                     1941.0
1
  Living Characters
                                             0ct-74
                            3061.0
                                                     1974.0
3
  Living Characters
                           2961.0
                                             Mar-63
                                                     1963.0
  Living Characters
                           2258.0
                                             Nov-50
                                                     1950.0
df = df.drop(columns = ['page id', 'name', 'urlslug', 'FIRST
APPEARANCE', 'Year'], axis = 1)
df.columns = df.columns.str.lower()
df.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 16376 entries, 0 to 16375
Data columns (total 8 columns):
#
     Column
                  Non-Null Count
                                   Dtvpe
- - -
 0
     id
                  12606 non-null
                                   object
 1
                  13564 non-null
     align
                                   object
 2
                  6609 non-null
                                   object
     eye
 3
     hair
                  12112 non-null
                                   object
 4
                  15522 non-null
     sex
                                   object
 5
     qsm
                  90 non-null
                                   object
 6
                  16373 non-null
                                   object
     alive
     appearances 15280 non-null
 7
                                   float64
dtypes: float64(1), object(7)
memory usage: 1023.6+ KB
sum(df.duplicated(df.columns))
7838
df = df.drop duplicates(df.columns, keep = 'last')
sum(df.duplicated(df.columns))
0
df.shape
(8538, 8)
df.isnull().sum()
               1454
id
align
               1346
               3138
eye
               1012
hair
```

```
sex 384 gsm 8448 alive 1 appearances 459 dtype: int64
```

Пропусков в столбце alive мало, можем их удалить.

```
df.dropna(subset=['alive'], inplace=True)
```

Узнаем количество уникальных значений в каждом столбце.

```
df.nunique()
```

```
id
                  4
                  3
align
                 24
eye
                 25
hair
                  4
sex
                  6
qsm
                  2
alive
                358
appearances
dtype: int64
```

df.gsm.value counts(dropna=False)

NaN	8447
Homosexual Characters	66
Bisexual Characters	19
Transgender Characters	2
Transvestites	1
Pansexual Characters	1
Genderfluid Characters	1
Name: gsm, dtype: int64	

В данной колонке много пустых значений, поэтому можем ее удалить.

```
df = df.drop(columns = ['gsm'], axis = 1)
```

Рассмотрим подробнее столбцы id, align, sex, alive.

```
df['id'].value counts(dropna=False)
```

```
Secret Identity 3491
Public Identity 2363
NaN 1453
No Dual Identity 1215
Known to Authorities Identity 15
Name: id, dtype: int64
```

Заменим пропуски значением Identity Unknown.

```
df['id'].fillna(value = "Identity Unknown", inplace = True)
```

```
df['align'].value counts(dropna=False)
Bad Characters
                      2873
Good Characters
                      2834
                       1485
Neutral Characters
NaN
                       1345
Name: align, dtype: int64
Заменим пропуски значением Neutral Characters.
df['align'].fillna(value = "Neutral Characters", inplace = True)
df['sex'].value counts(dropna=False)
Male Characters
                           5468
Female Characters
                           2643
                            383
NaN
Agender Characters
                             41
Genderfluid Characters
                              2
Name: sex, dtype: int64
Заполним пропуски значением Genderless Characters.
df['sex'].fillna(value = "Genderless Characters", inplace = True)
Рассмотрим столбец eye.
df['eye'].value counts(dropna=False)
                   3137
NaN
Blue Eves
                   1633
Brown Eyes
                   1413
Green Eyes
                    518
Black Eves
                    461
Red Eyes
                    418
                    333
White Eyes
                    234
Yellow Eyes
Grey Eyes
                     94
Hazel Eyes
                     76
Variable Eyes
                     49
Purple Eyes
                     31
Orange Eyes
                      25
Pink Eyes
                     21
One Eye
                      21
Gold Eves
                      14
Silver Eyes
                      12
Violet Eyes
                      11
Amber Eyes
                      10
Multiple Eyes
                      7
                      7
No Eyes
Yellow Eyeballs
                      6
Black Eyeballs
                       3
```

```
Magenta Eyes
Compound Eyes
                       1
Name: eye, dtype: int64
Сгрупируем значенияи избавимся от пропусков
eyes = ['Blue Eyes', 'Brown Eyes', 'Black Eyes', 'Green Eyes', 'Red
Eyes']
eyes new = []
for i in df.eye.values:
    if i not in eyes:
        eyes_new.append('Other color')
    else:
        eyes new.append(i)
df['eye'] = eyes_new
df['eye'].value counts(dropna=False)
Other color
               4094
Blue Eves
               1633
Brown Eyes
               1413
Green Eves
                518
Black Eyes
                461
Red Eyes
                418
Name: eye, dtype: int64
Аналогично поступим со столбцом hair.
df['hair'].value counts(dropna=False)
Black Hair
                          1890
Brown Hair
                          1370
Blond Hair
                          1033
NaN
                          1011
No Hair
                           815
                           535
Bald
White Hair
                           502
Red Hair
                           494
                           386
Grev Hair
                           107
Green Hair
Auburn Hair
                            74
Blue Hair
                            55
                            47
Purple Hair
Strawberry Blond Hair
                            47
                            43
Orange Hair
Variable Hair
                            32
Pink Hair
                            31
Yellow Hair
                            20
Silver Hair
                            16
Gold Hair
                             8
                             6
Reddish Blond Hair
                             6
Light Brown Hair
```

```
Magenta Hair
                             2
Orange-brown Hair
Bronze Hair
                             1
Dyed Hair
                             1
Name: hair, dtype: int64
hair = ['Black Hair', 'Brown Hair', 'Blond Hair', 'Red Hair', 'White
Hair']
hair new = []
for i in df.hair.values:
    if i not in hair:
        hair new.append('Other color')
        hair new.append(i)
df['hair'] = hair new
df['hair'].value counts(dropna=False)
Other color
               3248
Black Hair
               1890
Brown Hair
               1370
Blond Hair
               1033
White Hair
                502
                494
Red Hair
Name: hair, dtype: int64
Пропуски в столбце appearances заполним медианным значением.
df['appearances'] =
df['appearances'].fillna(df['appearances'].median())
df.isnull().sum()
id
               0
align
               0
               0
eye
               0
hair
sex
alive
               0
appearances
dtype: int64
```

#### Кодирование категориальных признаков

Теперь закодируем категориальные признаки с помощью Label Encoder.

```
le = LabelEncoder()
df['id'] = le.fit_transform(df['id'])
df['align'] = le.fit_transform(df['align'])
df['eye'] = le.fit_transform(df['eye'])
df['hair'] = le.fit_transform(df['hair'])
```

```
df['sex'] = le.fit transform(df['sex'])
df['alive'] = le.fit_transform(df['alive'])
df.head()
    id align eye hair sex alive appearances
                1 4 2 4
0
      4
                                                1
                                                                  4043.0

    1
    1
    5
    4
    1
    3360.0

    2
    1
    0
    4
    1
    3061.0

    1
    1
    0
    4
    1
    2961.0

    1
    1
    1
    4
    1
    2258.0

     3
1
2
     3
3
     3
      2
```

### Разделение выборки

Разделим выборку на обучающую и тестовую.

Целевым признаком выберем столбец alive (жив герой или нет).

## Метрики

```
def print_metrics(test, prediction):
    print("Accuracy:", accuracy_score(test, prediction))
    print("Precision:", precision_score(test, prediction))
```

# Логистическая регрессия

```
lr = LogisticRegression()
lr_prediction = lr.fit(x_train, y_train).predict(x_test)
print_metrics(y_test, lr_prediction)
```

Accuracy: 0.7295081967213115 Precision: 0.7295081967213115

По значению метрик можно сказать, что модель приблизительно на 73% идентифицирует как сам объект, так и его класс.

# Случайный лес

```
rf = RandomForestClassifier()
rf_prediction = rf.fit(x_train, y_train).predict(x_test)
print_metrics(y_test, rf_prediction)
```

Accuracy: 0.6221701795472288 Precision: 0.7164824603555983

В данном случае можно сделать вывод о том, что модель правильно классифицирует 62% объектов и при этом в 72% случаев верно определяет класс объекта.