PK Nº2

Прошкин Георгий Павлович ИУ5-61Б (Вариант 13)

Задание. Для заданного набора данных построить модели логистической регрессии и случайного леса. Оценить качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

Метод №1: Линейная/логистическая регрессия

Метод №2: Случайный лес

```
import numpy as np
import pandas as pd
from sklearn.preprocessing import LabelEncoder, MinMaxScaler
from sklearn.model selection import train test split
from sklearn.linear model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, precision_score,
recall score
df = pd.read csv('marvel-wikia-data.csv')
df.head()
   page id
                                            name
0
      1678
                      Spider-Man (Peter Parker)
      7139
                Captain America (Steven Rogers)
1
            Wolverine (James \"Logan\" Howlett)
2
     64786
3
              Iron Man (Anthony \"Tony\" Stark)
      1868
4
      2460
                            Thor (Thor Odinson)
                                    urlslug
0
               \/Spider-Man (Peter Parker)
                                              Secret Identity
         \/Captain America (Steven Rogers)
                                              Public Identity
1
2
   \/Wolverine_(James %22Logan%22 Howlett)
                                              Public Identity
3
     \/Iron Man (Anthony %22Tony%22 Stark)
                                              Public Identity
4
                     \/Thor (Thor Odinson)
                                             No Dual Identity
                ALIGN
                                                                 GSM
                              EYE
                                          HAIR
                                                            SEX
                                                                      \
0
      Good Characters Hazel Eyes
                                   Brown Hair
                                                Male Characters
                                                                 NaN
1
      Good Characters
                        Blue Eyes
                                   White Hair
                                                Male Characters
                                                                 NaN
2
   Neutral Characters
                        Blue Eves Black Hair
                                                Male Characters
                                                                 NaN
3
      Good Characters
                        Blue Eyes Black Hair Male Characters
                                                                 NaN
4
                                   Blond Hair Male Characters
      Good Characters
                        Blue Eyes
                                                                 NaN
```

```
ALIVE APPEARANCES FIRST APPEARANCE
                                                      Year
  Living Characters
                           4043.0
                                            Aug - 62
                                                    1962.0
1
  Living Characters
                           3360.0
                                            Mar-41
                                                    1941.0
2 Living Characters
                           3061.0
                                            0ct-74
                                                    1974.0
3 Living Characters
                                            Mar-63
                           2961.0
                                                    1963.0
4 Living Characters
                           2258.0
                                            Nov-50 1950.0
df = df.drop(columns = ['page_id', 'name', 'urlslug', 'FIRST
APPEARANCE', 'Year'], axis = 1)
df.columns = df.columns.str.lower()
df.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 16376 entries, 0 to 16375
Data columns (total 8 columns):
#
     Column
                  Non-Null Count
                                  Dtype
     -----
- - -
 0
     id
                  12606 non-null
                                  object
 1
     align
                  13564 non-null
                                  object
 2
                  6609 non-null
                                  object
     eye
 3
    hair
                  12112 non-null
                                  object
                  15522 non-null
 4
    sex
                                  object
 5
                  90 non-null
                                  obiect
     gsm
                  16373 non-null
 6
                                  object
     alive
7
     appearances 15280 non-null
                                  float64
dtypes: float64(1), object(7)
memory usage: 1023.6+ KB
sum(df.duplicated(df.columns))
7838
df = df.drop duplicates(df.columns, keep = 'last')
sum(df.duplicated(df.columns))
0
df.shape
(8538, 8)
df.isnull().sum()
id
               1454
align
               1346
               3138
eye
               1012
hair
                384
sex
               8448
gsm
alive
                  1
```

```
459
appearances
dtype: int64
Пропусков в столбце alive мало, можем их удалить.
df.dropna(subset=['alive'], inplace=True)
Узнаем количество уникальных значений в каждом столбце.
df.nunique()
id
                 4
                 3
align
                24
eye
hair
                25
                 4
sex
                 6
gsm
                 2
alive
appearances
               358
dtype: int64
df.gsm.value counts(dropna=False)
                          8447
Homosexual Characters
                            66
Bisexual Characters
                            19
Transgender Characters
                             2
Transvestites
                             1
Pansexual Characters
                             1
Genderfluid Characters
                             1
Name: gsm, dtype: int64
В данной колонке много пустых значений, поэтому можем ее удалить.
df = df.drop(columns = ['gsm'], axis = 1)
Рассмотрим подробнее столбцы id, align, sex, alive.
df['id'].value counts(dropna=False)
Secret Identity
                                 3491
Public Identity
                                  2363
```

```
Known to Authorities Identity 15
Name: id, dtype: int64
```

No Dual Identity

Заменим пропуски значением Identity Unknown.

```
df['id'].fillna(value = "Identity Unknown", inplace = True)
df['align'].value_counts(dropna=False)
```

1453

1215

```
Bad Characters
                      2873
Good Characters
                      2834
Neutral Characters
                      1485
NaN
                      1345
Name: align, dtype: int64
Заменим пропуски значением Neutral Characters.
df['align'].fillna(value = "Neutral Characters", inplace = True)
df['sex'].value counts(dropna=False)
Male Characters
                          5468
Female Characters
                          2643
NaN
                           383
Agender Characters
                             41
Genderfluid Characters
                             2
Name: sex, dtype: int64
Заполним пропуски значением Genderless Characters.
df['sex'].fillna(value = "Genderless Characters", inplace = True)
Рассмотрим столбец eye.
df['eye'].value counts(dropna=False)
                   3137
NaN
Blue Eyes
                   1633
                   1413
Brown Eyes
                    518
Green Eyes
Black Eyes
                    461
Red Eyes
                    418
White Eyes
                    333
Yellow Eyes
                    234
                     94
Grey Eyes
Hazel Eyes
                     76
Variable Eyes
                     49
Purple Eyes
                     31
Orange Eyes
                     25
Pink Eyes
                     21
One Eye
                     21
Gold Eyes
                     14
Silver Eyes
                     12
Violet Eyes
                     11
Amber Eyes
                     10
Multiple Eyes
                      7
                      7
No Eyes
Yellow Eyeballs
                      6
                      3
Black Eyeballs
Magenta Eyes
```

```
Compound Eyes
Name: eye, dtype: int64
Сгрупируем значенияи избавимся от пропусков
eyes = ['Blue Eyes', 'Brown Eyes', 'Black Eyes', 'Green Eyes', 'Red
Eyes']
eyes new = []
for i in df.eye.values:
    if i not in eyes:
        eyes_new.append('Other color')
    else:
        eyes new.append(i)
df['eye'] = eyes new
df['eye'].value counts(dropna=False)
Other color
               4094
Blue Eves
               1633
Brown Eyes
               1413
Green Eyes
              518
Black Eves
                461
Red Eyes
                418
Name: eye, dtype: int64
Аналогично поступим со столбцом hair.
df['hair'].value counts(dropna=False)
Black Hair
                         1890
Brown Hair
                         1370
Blond Hair
                         1033
NaN
                         1011
No Hair
                          815
Bald
                          535
White Hair
                           502
                          494
Red Hair
Grey Hair
                           386
Green Hair
                           107
                            74
Auburn Hair
Blue Hair
                           55
Purple Hair
                            47
Strawberry Blond Hair
                           47
Orange Hair
                           43
Variable Hair
                            32
Pink Hair
                            31
                            20
Yellow Hair
Silver Hair
                            16
Gold Hair
                            8
Reddish Blond Hair
                            6
Light Brown Hair
                             6
                             5
Magenta Hair
```

```
Orange-brown Hair
                            2
                             1
Bronze Hair
Dyed Hair
                             1
Name: hair, dtype: int64
hair = ['Black Hair', 'Brown Hair', 'Blond Hair', 'Red Hair', 'White
Hair']
hair new = []
for i in df.hair.values:
    if i not in hair:
        hair new.append('Other color')
    else:
        hair new.append(i)
df['hair'] = hair new
df['hair'].value counts(dropna=False)
Other color
               3248
Black Hair
               1890
Brown Hair
               1370
Blond Hair
               1033
White Hair
                502
Red Hair
                494
Name: hair, dtype: int64
Пропуски в столбце appearances заполним медианным значением.
df['appearances'] =
df['appearances'].fillna(df['appearances'].median())
df.isnull().sum()
id
               0
align
               0
eye
               0
hair
               0
sex
alive
               0
appearances
dtype: int64
```

Кодирование категориальных признаков

Теперь закодируем категориальные признаки с помощью Label Encoder.

```
le = LabelEncoder()
df['id'] = le.fit_transform(df['id'])
df['align'] = le.fit_transform(df['align'])
df['eye'] = le.fit_transform(df['eye'])
df['hair'] = le.fit_transform(df['hair'])
df['sex'] = le.fit_transform(df['sex'])
df['alive'] = le.fit_transform(df['alive'])
```

```
df.head()
  id align eye hair sex alive appearances
0
         1
            4 2
                                    4043.0
                            1 3360.0
1 3061.0
1 2961.0
1 2258.0
1
   3
         1
              1
                  5
                      4
2
  3
         2
             1
                  0 4
                   0 4
1 4
3
   3
         1
              1
  2
         1
              1
```

Разделение выборки

Разделим выборку на обучающую и тестовую.

Целевым признаком выберем столбец alive (жив герой или нет).

Метрики

```
def print_metrics(test, prediction):
    print("Accuracy:", accuracy_score(test, prediction))
    print("Precision:", precision score(test, prediction))
```

Логистическая регрессия

```
lr = LogisticRegression()
lr_prediction = lr.fit(x_train, y_train).predict(x_test)
print_metrics(y_test, lr_prediction)
```

Accuracy: 0.7295081967213115 Precision: 0.7295081967213115

По значению метрик можно сказать, что модель приблизительно на 73% идентифицирует как сам объект, так и его класс.

Случайный лес

```
rf = RandomForestClassifier()
rf_prediction = rf.fit(x_train, y_train).predict(x_test)
print_metrics(y_test, rf_prediction)
```

Accuracy: 0.6221701795472288 Precision: 0.7164824603555983

В данном случае можно сделать вывод о том, что модель правильно классифицирует 62% объектов и при этом в 72% случаев верно определяет класс объекта.